

一種結合階層式 Q 學習與力場感知路由之 無線可充電感測網路多充電車排程方法

陶亮清¹、王丕中²

國立中興大學 資訊工程學系

國科會計畫編號：NSTC 114-2221-E-005-043-MY3

摘要

無線可充電感測網路 (WRSN) 可透過行動充電車為節點補電，但多充電車排程需同時權衡節點死亡風險、移動成本、回站可行性與車輛協調；若僅依局部急迫度選擇目標，容易造成重複服務或高風險區域延遲。本文提出 **HQARRF**，以 **ARR-F** 候選叢集評分為下層路由，輔以自適應區域風險估計與 **Q-learning** 上層介入控制，使充電車在局部服務效益與全域風險間取得平衡。模擬結果顯示，HQARRF 相較 Genetic+2-OPT、MCCA、UCMC、K-EDF 與 NJNP 可提升感測節點存活率，並兼顧移動距離、傳遞能量與多充電車負載平衡。

27 個參數點中取得
最高感測節點存活率

26/27

五組具完整重複實驗資料的情境

相對五種基準方法
平均值的存活率提升

+20.7

個百分點

對「各點最強基準」
仍維持的領先幅度

+11.2

個百分點 (17 個參數點)

僅用 2 台充電車即超越
其他方法 7 台的最佳表現

0.750

vs. 0.660 (他法 7 台)

一、研究問題與系統模型

- 感測節點因感測、傳輸與多跳轉發而有不同耗能速率，低能量節點分散於不同區域；充電車本身亦受移動能量、服務時間與回站可行性限制。
- 既有方法多偏重局部請求、移動距離或固定分群，較少同時處理區域風險、時間到死亡與多充電車協調。
- 場域 $L \times L$ 、 N 個節點、1 座基地台、 M 台充電車；充電效率隨距離衰減
 $\eta(d) = \lambda / (d + \beta_c)^2$ ，節點時間到死亡
 $TTD_i = E_i(t) / c_i(t)$ 。




圖 1. 模擬場域、候選叢集與多充電車目標示意

二、HQARRF 階層式排程架構

上層 Q-learning 介入控制器

狀態 $s = (z^*, g, b) \rightarrow$ 索引 $9z^* + 3g + b$ (區域層級摘要，非全節點狀態)

動作 $a \in \{ \text{不介入}, \text{介入合法高風險區域 } z \}$ ϵ -greedy，線上更新

獎勵 $r = \text{存活} \uparrow + \text{風險} \downarrow + \text{危急節點} \downarrow + \text{傳遞能量} \uparrow - \text{死亡} - \text{移動} - \text{介入成本}$

$\uparrow$ Risk_{smooth}, CR_z

$\downarrow$ 介入 $\rightarrow$ 候選限縮至區域

自適應區域風險與覆蓋不足估計

危急節點密度 ρ_z · 服務容量 Cap_z · 充電車覆蓋比 CR_z

slack = TTD - ETA $\rightarrow$ 節點風險 $\rightarrow$ 區域風險 Risk_z $\rightarrow$ 鄰域平滑

$\uparrow$ 節點剩餘能量 · TTD

$\downarrow$ 區域內合法候選叢集

下層 ARR-F 候選叢集評分與路由

吸引力 A (叢集電荷 Q) · 斥力 Φ (他車已保留停靠點) · 力場 F (鄰近危急節點)

$c^* = \text{argmax } S_c \rightarrow$ 可行性檢查 (須保留返回基地台的能量)

$\downarrow$ 派遣充電車 $m \rightarrow$ 停靠點 d_c ，事件驅動下一次決策

分工明確：下層以可解釋的吸引 / 斥力排序候選目標，上層僅在區域風險高且覆蓋不足時介入，不把所有節點與充電車的組合交給單一大型學習模型處理。

區域數敏感度：將區域數 Z 由 2 掃描至 16，存活率呈明顯的倒 U 形 —— $Z=6$ 附近最佳 (0.768)， $Z=2$ 與 16 則分別降至 0.564 與 0.668，佐證自適應區域數的作法。

三、下層 ARR-F 目標評分

$$S_c = A_c - \beta \Phi_c + \lambda_f F_c, \quad c^* = \text{argmax}_c S_c$$

- A_c 吸引力：服務急迫度經 min-max 正規化後映為叢集電荷 $Q_c = 1 - 2\hat{U}_c$ ，高急迫叢集形成較強吸引，並以停靠點距離平方衰減。
- Φ_c 斥力：其他充電車已保留停靠點所形成的 softened inverse-square 場，降低多車重複造訪同一叢集 ($\beta=0.2$)。
- F_c 力場感知：半徑 $R_f=150$ m 內最近 $K_f=10$ 個危急節點的加權貢獻，強化低能量節點附近的權重 ($\lambda_f=1.0$ ，危急判定門檻為能量比例 0.3)。
- 消融序列由簡至繁：AR (僅吸引力) $\rightarrow$ ARR (加入斥力 Φ) $\rightarrow$ ARR-F (再加入力場 F)，三者存活率逐步改善。

結論

- 本文提出 HQARRF：以 ARR-F 的吸引 / 斥力與力場感知作為下層候選叢集評分，並以自適應區域風險估計驅動 Q-learning 上層介入，形成可解釋且分工明確的多充電車排程框架。
- HQARRF 在耗能率、節點數量、電池容量、充電車數量、場域大小與充電車速度設定下皆能提升節點存活表現；於其中五組具完整重複實驗資料的情境、合計 27 個參數點中有 26 點取得最高存活率，相對五種基準方法平均值提升約 20.7 個百分點。
- 適用限制與未來工作：當節點分布極稀疏、充電壓力很低，或高風險節點長期集中於單一小區域時，區域介入的額外效益可能下降；區域過大會使風險估計被平均化，過小則造成介入判斷波動。後續將延伸至能量收集節點與大規模場域的計算效率分析，並以 meta-learning 自動調整 θ_r 、 θ_c 與區域數。

四、實驗設定與比較方法

模擬時間	100000 s	充電 / 通訊半徑	30 / 80 m
場域大小	1000 × 1000 m	充電功率	10 W
感測節點數量	250	充電車最大電量	10000 J
節點最大電量	150 J	充電模型參數	$\lambda=36.0, \beta_c=30.0$
節點耗能率	1.0×10^{-3} J/s	介入風險門檻 θ_r	0.45
行動充電車數量	5	介入覆蓋門檻 θ_c	0.80
充電車速度	5 m/s	每參數點重複模擬	5 組亂數種子

比較方法涵蓋三種角度：路徑最佳化 (Genetic+2-OPT)、多充電車合作與不均勻叢集式充電 (MCCA、UCMC)、不使用學習模型的局部啟發式 (K-EDF、NJNP)。各方法共用同一套模擬核心與充電模型，並一律加入回站可行性檢查。

五、實驗結果





圖 2. 不同節點耗能率下的存活率 —— 充電壓力越高，風險感知的優勢越明顯




圖 3. 不同充電車數量下的存活率 —— 效益來自排程決策品質而非車輛數量




圖 4. 多充電車移動負載平衡 —— CV 越低代表任務分配越均衡

統計驗證：對耗能率、節點數量與電池容量三組情境共 17 個參數點，與「各點最強的非 HQARRF 方法」成對比較，採 exact Mann-Whitney U 檢定並以 Cliff's delta 衡量效應量 —— 11 點達 large 效應量、5 點完全分離 ($d = +1.000$)、6 點 $p < 0.05$ ，平均領先 11.2 個百分點。本文不主張在所有設定下皆具顯著優勢，而是主張其在高充電壓力情境中同時具備統計顯著性與大效應量。

移動成本：HQARRF 移動距離居中至偏高，反映主動前往高風險節點的特性，但傳遞能量仍高於其他方法。