

一種結合階層式 Q 學習與力場感知路由之無線可充電感測網路多充電車排程方法

¹陶亮清, ²王丕中

¹國立中興大學 資訊工程學系

liangkingtao@gmail.com, *通訊作者: liangkingtao@gmail.com

²國立中興大學 資訊工程學系

pcwang.tw@gmail.com

摘要

無線可充電感測網路 (Wireless Rechargeable Sensor Networks, WRSNs) 可透過行動充電車為節點補能, 但多充電車排程需兼顧節點死亡風險、移動成本、回站可行性與車輛協調。若只依局部急迫度選擇目標, 容易造成重複服務或高風險區域延遲。本文提出 HQARRF, 結合 ARR-F 候選叢集評分、區域風險估計與 Q-learning 介入控制, 使充電車在局部服務效益與全域風險間取得平衡。模擬結果顯示, HQARRF 相較 Genetic+2-OPT、MCCA、UCMC、K-EDF 與 NJNP 可提升感測節點存活率, 並兼顧移動距離、傳遞能量與多充電車負載平衡。

關鍵詞: 無線可充電感測網路、行動充電車、多充電車排程、Q 學習、力場感知路由、區域風險估計

一、介紹

無線感測網路廣泛應用於環境監測與工業物聯網等場景, 但感測節點通常受限於電池容量與部署位置, 長時間運作後容易因能量耗盡而失效。無線能量傳輸技術使行動充電車能在不更換電池的情況下補充節點能量, 因此形成無線可充電感測網路的重要研究方向 [1]–[3]。

在多充電車 WRSN 中, 充電策略不只是路徑規劃問題。感測節點因感測、傳輸與多跳轉傳而有不同耗能速率, 低能量節點可能分散於不同區域; 行動充電車本身則受移動能量、服務時間與回站充電可行性的限制。

既有研究已探討單充電車或多充電車排程、分群充電與路徑最佳化 [4]–[8], 但多數方法偏重局部請求、移動距離或固定分群結構, 較少同時結合區域風險、時間到死亡與多充電車協調。

本文提出 HQARRF (Hierarchical Q-learning and Force-aware Routing), 將多充電車排程視為風險感

知資源分配問題。本文貢獻如下: (1) 提出 ARR-F 下層路由分數, 以吸引力、斥力與力場感知項整合局部急迫度與充電車協調; (2) 建立自適應區域與區域風險估計, 使排程能觀察局部叢集以外的服務不足區域; (3) 使用 Q-learning 作為上層介入控制器, 判斷何時將充電車導向高風險區域; (4) 透過多組模擬比較驗證 HQARRF 在節點存活與多指標取捨上的效果。

二、文獻探討

早期 WRSN 研究主要關注能量補充模型、充電請求排程與感測節點壽命延長。Xie 等人提出以無線能量補充延長感測網路生命週期的觀點 [1], He 等人則討論能量供應與網路覆蓋間的關係 [2]。

在充電路徑與分群方法方面, 研究者提出不均勻分群、同時多節點充電、行動資料收集與能量補充等方法 [5], [6]。多充電車環境進一步帶來任務分配與協調挑戰, 例如 MCCA 透過多充電車合作安排低能量請求節點 [7], UCMC 則利用不均勻叢集改善充電配置 [6]。

近年也有研究將強化學習應用於充電排程與充電車佈局 [10], [11]。這些方法提供動態決策能力, 但若直接以學習模型取代完整路由, 可能增加狀態空間與訓練複雜度。

綜合而言, 既有方法大致可分為路徑成本導向、分群服務導向與學習式排程三類。路徑成本導向方法可降低移動距離, 但較難保證危急節點被即時服務; 分群服務導向方法可提升同時充電效率, 但若分群邊界固定, 可能無法反映動態風險; 學習式方法具有適應性, 但需控制模型複雜度。HQARRF 的設計即是將局部路由與區域層級學習拆開, 使兩者分別處理可解釋的候選目標選擇與上層風險介入。

三、系統模型

本文考慮一個部署於 $L \times L$ 二維場域的 WRSN。系統包含 N 個感測節點、一個基地台與 M 台行動充電

車。感測節點週期性執行感測與資料傳輸，並透過多跳通訊將資料送回基地台。若節點能量低於死亡門檻，該節點將無法繼續感測或轉傳資料，可能造成覆蓋率下降與通訊連通性受損。




圖 1. HQARRF 模擬場域、候選叢集與多充電車目標示意

令 $E_i(t)$ 為節點 i 在時間 t 的剩餘能量， $E_i^{\max}$ 為其最大電量， $c_i(t)$ 為耗能速率；與實作一致，時間到死亡以目前剩餘能量除以耗能速率估計：

$$e_i(t) = \frac{E_i(t)}{E_i^{\max}}, \quad TTD_i = \frac{E_i(t)}{c_i(t)} \quad (1)$$

充電決策以候選叢集與停靠點為基本單位（如圖 1）：當充電車 m 停靠於候選叢集 c 的停靠點 d_c 時，位於充電半徑 R_a 內且仍存活的節點可被同時服務。充電效率採距離衰減模型：

$$\eta(d) = \frac{\lambda}{(d + \beta_j)^2} \quad (2)$$

充電車執行任務時必須保留足夠能量返回基地台，避免因追逐高風險目標而耗盡自身能量；若前往候選目標後無法保留返回所需能量，該目標即被視為不可行。

四、HQARRF 方法

HQARRF 採兩層式排程架構。下層 ARR-F 負責候選叢集與停靠點選擇，上層區域風險/Q-learning 機制負責判斷是否需要將充電車導向高風險區域。以下從下層至上層依序介紹各元件設計。

(一) 下層 ARR-F 候選叢集評分

ARR-F 先把每個候選叢集的服務急迫度壓縮成一個電荷，再用靜電吸引力與斥力（electrostatic

attraction/repulsion）產生原始分數，最後對同一輪候選叢集做 min-max 正規化。令 d_c 為叢集 c 的停靠點， $d_{m,c} = \|p_m(t) - d_c\|$ 。急迫度 U_c 以能量缺口為主項，加權整合耗能率、危急度與存活節點數，其中混合能量比例 $\tilde{e}_c = 0.1\tilde{e}_c^{\min} + 0.9\tilde{e}_c^{\text{avg}}$ 同時保留最低能量警訊與整體叢集健康； U_c 經 min-max 正規化後得到 $\hat{U}_c$ ，並映射為叢集電荷 $Q_c = 1 - 2\hat{U}_c$ （高急迫叢集形成較強吸引）：

$$A_c^{\text{raw}} = - \frac{k_a q_m Q_c}{d_{m,c}^2 + \varepsilon_a^2} \quad (3a)$$

斥力以其他充電車到候選停靠點的 softened inverse-square 場表示：

$$\Phi_c = \frac{\sum_{m' \neq m} \frac{1}{d_{m',c}^2 + \varepsilon_r^2}}{\max_j \sum_{m' \neq m} \frac{1}{d_{m',j}^2 + \varepsilon_r^2}} \quad (3b)$$

$$F_c = \log(1 + \sum_{i \in \text{Top}K_f(c)} \frac{1 - e_i}{\|p_i - d_c\|^2 + \varepsilon_f^2}) \quad (3c)$$

$$S_c = A_c - \beta \Phi_c + \lambda_f F_c, \quad c^* = \text{argmax}_c S_c \quad (3d)$$

式 (3a)–(3c) 中各常數的物理意義如下。 k_a 為靜電類比中的比例常數， q_m 為充電車 m 的單位電荷量；由於同一輪決策中 $k_a q_m$ 對所有候選叢集皆為定值，兩者只決定 A_c^{raw} 的整體尺度，經 min-max 正規化後不影響候選排序，故實作上取 $k_a = q_m = 1$ 。叢集電荷 $Q_c = 1 - 2\hat{U}_c$ 將正規化急迫度映射至 $[-1, 1]$ ：高急迫叢集 $Q_c \rightarrow -1$ ，式 (3a) 的負號使其產生強吸引；低急迫叢集 $Q_c \rightarrow +1$ 則轉為輕微排斥，可自然抑制對已充足叢集的重複造訪。

ε_a 、 ε_r 、 ε_f 為軟化常數（softening constants），單位與距離平方相同，用於避免充電車或節點與停靠點重合時分母趨近於零而使分數發散，三者實作均取 10^{-6} 。式 (3c) 的力場作用半徑 $R_f = 150$ m 界定哪些危急節點會影響停靠點評分； $K_f = 10$ 則限制每個候選叢集最多納入距離最近的 10 個危急節點。力場係數 $\lambda_f = 1.0$ ，危急判定門檻為能量比例 0.3。

式 (3a) 中 A_c^{raw} 經 min-max 正規化後為 A_c 。 β 為斥力強度係數，數值越大越抑制多台充電車選擇相鄰停靠點；本文經參數掃描取 $\beta = 0.2$ 。當 $\lambda_f = 0$ 時即為 ARR；再令 $\beta = 0$ 則退化為只看吸引力的 AR。

在實作上，ARR-F 會先排除已被其他充電車保留或不含存活節點的候選叢集，再對剩餘候選目標計算

正規化吸引力與斥力，使 ARR-F 能在局部決策中兼顧急迫性、服務量與多充電車分散性。

(二) 區域風險與覆蓋不足估計

區域風險估計將場域切分為多個自適應區域（區域數隨充電車數量自動調整），每個區域依序計算危急節點密度、充電車覆蓋充足性與節點個體時間到死亡風險，共同作為 Q-learning 上層介入的判斷依據。

具體而言，對區域 z ，令 V_z^{alive} 為存活節點集合、 V_z^{crit} 為危急節點集合，則危急節點密度定義為：

$$\rho_z^{crit} = \frac{|V_z^{crit}|}{|V_z^{alive}|} \quad (4)$$

服務容量 Cap_z 依危急節點數決定（ $|V_z^{crit}|$ 分段量化：0→0、1→1、2→2、≥5→3，並以充電車總數 M 取上界），是後續覆蓋充足性評估的基準； ρ_z^{crit} 則以 $|V_z^{alive}|$ 正規化，使各區危急程度不受存活節點數規模影響而可跨區比較，並用於動態調整危急能量門檻。

充電車覆蓋比例 CR_z 以 Cap_z 為需求基準，衡量現有充電車覆蓋 Cov_z 是否充足：

$$CR_z = \min \left(1, \frac{Cov_z}{\max(Cap_z, 1)} \right) \quad (5)$$

CR_z 偏低代表覆蓋不足，但不足以反映節點個體緊迫程度。HQARRF 進一步以時間到死亡 TTD_i 與充電車預估抵達時間 ETA_i 計算 slack，轉換為節點風險：

$$ETA_i = \frac{\min_m ||p_i - p_m(t)||}{v_m}, \quad slack_i = TTD_i - ETA_i \quad (6a)$$

$$u_i = \begin{cases} \exp(-slack_i/\tau), & slack_i \geq 0 \\ 1 + b_{miss}, & slack_i < 0 \end{cases} \quad (6b)$$

$$Risk_z^{raw} = \frac{1}{K_z} \sum_{i \in TopK(z)} u_i \quad (6c)$$

其中 τ 為衰減時間常數， b_{miss} 為已超出充電窗口的懲罰項。為避免固定區域邊界造成風險估計跳變，HQARRF 以鄰近區域集合 $N(z)$ 對原始風險進行平滑，其中 μ 為平滑係數：

$$Risk_z^{smooth} = (1 - \mu) \cdot Risk_z^{raw} + \mu \cdot \frac{1}{|N(z)|} \sum_{z' \in N(z)} Risk_{z'}^{raw} \quad (6d)$$

(三) Q-learning 介入控制

以 $Risk_z^{smooth}$ 與 CR_z （式 (5)(6d)）為輸入，Q-learning 上層控制器決定是否介入。動作空間包含「不介入」與「選擇某一合法高風險區域介入」；實作上 $a_t=0$ 表示不介入， $a_t=z+1$ 表示介入區域 z ，合法候選須同時滿足（ θ_r 、 θ_c 為門檻）：

$$Risk_z^{smooth} \geq \theta_r, \quad Cap_z > 0, \quad CR_z < \theta_c \quad (7)$$

Q-learning 的 state 不直接儲存所有節點，而是用區域層級摘要表示。實作中的 tuple 與 Q 表索引為：

$$s_t = (z_t^*, g_t, b_t), \quad id(s_t) = 9z_t^* + 3g_t + b_t \quad (8)$$

其中 $z_t^* = \arg\max_z Risk_z^{smooth}$ ； g_t 將全域最大平滑風險、 b_t 將最大覆蓋不足量 $\max_z (Risk_z^{smooth} - CR_z)$ 各離散為三階（0/1/2），故索引式以 3 為基底將三維狀態唯一編碼至一維整數。動作 a_t 包含不介入與選擇合法區域介入，其價值以標準 Q-learning [9] 更新（ $\alpha_Q=0.1$ 為學習率， $\gamma_Q=0.9$ 為折扣因子）：

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha_Q [r_t + \gamma_Q \max_{a'} Q(s_{t+1}, a') - Q(s_t, a_t)] \quad (9)$$

獎勵 r_t 由前一次決策至本次決策之間的系統狀態變化計算，包含服務效益與成本兩類項目：

$$r_t = w_a \Delta N^{alive} + w_r \Delta R + w_c \Delta N^{crit} + w_e \Delta E^{deliv} - w_d \Delta N^{dead} - w_v \Delta D^{move} - w_x \cdot 1[a_t > 0] \quad (10)$$

其中 ΔN^{alive} 為存活節點數增量、 $\Delta R = \sum_z Risk_z^{smooth}$ 的下降量、 ΔN^{crit} 為危急節點數的下降量、 ΔE^{deliv} 為累計傳遞能量增量（J）、 ΔN^{dead} 為新增死亡節點數、 ΔD^{move} 為期間充電車移動距離增量（m），末項為介入動作的固定成本（ $a_t > 0$ 時為 1）。各項均以原始物理量代入，不另作正規化；量綱差異由權重吸收，故移動距離權重 w_v 數量級明顯小於節點數相關權重。本文採用的權重為 $w_a=5.0$ 、 $w_r=3.0$ 、 $w_c=1.5$ 、 $w_e=0.5$ 、 $w_d=12.0$ 、 $w_v=0.005$ 、 $w_x=0.1$ 。其中 w_d 明顯高於 w_a ，使控制器對「造成節點死亡」的懲罰重於「救回節點」的獎勵，符合本文以存活率為首要目標的設計； w_x 則避免在效益不明確時仍頻繁介入。

實作時，Q 表儲存不同區域風險狀態下的動作偏好。系統以 ϵ -greedy 在合法動作中選擇是否介入；若充電車位置不適合或原本任務較急迫，則保守地維持 ARR-F 指派。當介入成立時，再於目標區域內依時間

到死亡與局部危急度選出節點，使上層決策仍受可行路由約束。

由於排程採事件驅動，決策時點並非等間隔，上層控制實質上是以「決策事件」為時間軸的半馬可夫決策過程： s_t 取自全域區域層級快照而非個別充電車的局部觀測，所有充電車共用單一 Q 表；某車觸發決策後暫存 (s_t, a_t) ，待下次任一充電車觸發時，再以新快照與期間累積的變化計算 r_t 並依式 (9) 更新。因此索引 t 為決策事件序號而非固定時距，其他充電車的動作則視為環境動態的一部分。

Q-learning 以線上 (online) 方式運作，不區分訓練與測試：每次模擬自全零初始化的 Q 表開始，於單一連續軌跡中邊決策邊更新，且不跨場景保留 Q 表，故無離線訓練回合 (episode) 之概念，評估數據亦包含探索行為在內。探索率 ε 由 0.3 起始、每次更新後乘以 0.995 並以 0.05 為下限，不另設提前停止的收斂判準。

(四) 事件驅動流程與可行性檢查

整體排程採事件驅動設計：僅在充電車需要新目標時觸發一次決策回合；無論最終採 Q-learning 介入目標或 ARR-F 本地指派，均須通過前往目標並返回基地台的能量檢查才會正式派遣。整體排程流程整理如演算法 1。

演算法 1：HQARRF 單一決策回合

輸入：節點集合 S 、充電車集合 M 、基地台 B
 輸出：各閒置充電車的充電目標
 1 更新所有節點能量、TTD 與充電請求
 2 建立候選叢集 C 與停靠點 d_c
 3 劃分自適應區域並估計各區風險 r_z
 4 **for** 每台閒置充電車 m **do**
 5 $a \leftarrow$ Q-learning 由 {不介入, 高風險區域} 選動作
 6 **if** $a =$ 介入區域 z **then** 限定候選為 z 內叢集
 7 以 ARR-F 力場模型計算 $S_c = A_c - \beta \cdot \Phi_c + \lambda_f F_c$
 8 選分數最高且可返回 B 的候選叢集 c^*
 9 **if** c^* 存在 **then** 指派 $m \rightarrow d_{c^*}$ 並標記保留
 10 更新 Q 值並回收完成任務之充電車

五、實驗結果

實驗以 Python WRSN 模擬器進行，預設場域為 $1000 \text{ m} \times 1000 \text{ m}$ 、250 個感測節點、5 台行動充電車，模擬時間為 100000 秒。除特殊情境外，基地台位於場域中心，感測節點初始能量由最大電量的 20% 至 100% 隨機設定；主要比較情境之各參數點以 5 組

亂數種子重複模擬，且各方法在同一組種子下成對比較，以降低單一隨機配置造成的偏差。

本文比較 HQARRF 與 Genetic+2-OPT、MCCA、UCMC、K-EDF、NJNP 等方法。評估指標包含節點存活率、總移動距離、傳遞至節點的能量、移動負載平衡，以及不同耗能率下的穩定性。

表 I. 預設實驗參數

參數	值
模擬時間	100000 s
場域大小	$1000 \text{ m} \times 1000 \text{ m}$
感測節點數量	250
感測節點最大電量	150 J
感測節點耗能率	$1.0 \times 10^{-3} \text{ J/s}$
行動充電車數量	5
充電車速度	5 m/s
充電半徑	30 m
通訊半徑	80 m
充電車最大電量	10000 J
充電功率	10 W
充電模型參數	$\lambda=36.0, \beta_c=30.0$
介入風險門檻 θ_f	0.45
介入覆蓋門檻 θ_c	0.8

本文比較的基準方法涵蓋三種角度：Genetic+2-OPT 為路徑最佳化基準，依 [8] 的多充電車時間窗排程架構實作；MCCA 與 UCMC 分別依 [7] 與 [6] 重新實作，代表既有的多充電車合作與不均勻叢集式充電設計；K-EDF 與 NJNP 則為本文自行實作、不使用學習模型的局部啟發式對照，前者依時間到死亡選擇前 K 個急迫請求，後者採最近任務／最近節點優先並避免同回合重複指派。各方法的充電請求門檻統一設為最大電量的 20%。為確保比較公平，所有方法共用同一套模擬核心（節點耗能、式 (2) 的距離衰減充電模型、充電半徑與充電車速度），差異僅在目標選擇與排程策略；原未考慮充電車自身能量上限者，一律加入與本文相同的返回基地台可行性檢查，避免因忽略回站限制而取得不對等的移動優勢。

(一) ARR-F 消融分析

在進行整體比較之前，本文先以消融實驗釐清下層路由由分數各組成的貢獻，並說明後續比較中為何同時納入 AR、ARR 與 ARR-F 三個版本。AR

(Attraction-based Routing) 僅考慮吸引力，容易集中

於局部急迫區域；ARR (+Repulsion) 在吸引力之外加入斥力 Φ ，可降低多充電車同時選擇相同目標的機率；ARR-F (+Force-field) 再加入低能量節點的力場感知，強化停靠點附近危急節點的權重。三者構成由簡至繁的方法序列，作為 HQARRF 下層路由的逐步建構基礎。本文對 β 進行代表性場景下的參數掃描，並採用使存活率最佳的設定以確保消融比較的公平性。




圖 2. ARR-F 消融版本 (AR、ARR、ARR-F) 之感測節點存活率變化

圖 2 顯示三個版本的存活率隨時間變化。從 AR 到 ARR 再到 ARR-F，存活趨勢逐步改善，說明僅以局部急迫度作為目標並不足夠；避免重複服務與提高低能量節點權重皆對長期存活有正面影響。加入斥力與力場感知雖可能略增移動成本，但換取的存活率提升使整體更為有利。

三個版本在模擬前期差距不大，可由式 (3b)、(3c) 的作用條件解釋：初期絕大多數節點的能量比例仍高於危急門檻 0.3，力場項的來源集合幾乎為空 ($F_c \approx 0$)，ARR-F 在數值上退化為 ARR；同時候選叢集數量充足，充電車不易競逐同一停靠點，斥力 Φ_c 亦少有實際作用，ARR 又趨近 AR。待節點能量分布分化、危急節點成群出現後，兩項才逐步發揮作用，故三者的差距是隨充電壓力累積而展開。

(二) 整體存活率比較

存活率是本文最主要的評估指標。圖 3 至圖 6 分別在不同節點耗能率、感測節點數量、電池容量與行動充電車數量下，比較 HQARRF 與 ARR-F 家族及其他基準方法；圖 7 以重複實驗穩定性補強前述比較的可信度。本文另於場域大小與充電車速度下進行相同比較（因版面所限未列存活率圖）；上述情境中具備完整重複實驗資料者共五組，合計 27 個參數點，HQARRF 在其中 26 點取得最高感測節點存活率，相對五種基準方法平均值提升約 20.7 個百分點，即使僅

與各參數點表現最佳的方法相比，仍平均領先 9.2 個百分點。




圖 3. 不同節點耗能率下的感測節點存活率




圖 4. 不同感測節點數量下的感測節點存活率




圖 5. 不同感測節點電池容量下的感測節點存活率

上述三組情境的比較一致顯示，HQARRF 的存活率優勢不依賴特定參數條件：在耗能率較高時（圖 3），風險感知設計的優勢更為明顯；節點數增加時（圖 4），區域介入有效分攤多充電車的服務壓力；電池容量較低時（圖 5），整體存活率下降，但 HQARRF 的相對領先仍維持，顯示主動風險服務在高壓力場景中更具效益。

圖 6 顯示，隨行動充電車數量增加，各方法的感測節點存活率整體上升。HQARRF 在各充電車數量下

均維持最高存活率，且僅使用 2 台充電車時 (0.750) 即已超越其他方法使用 7 台時的最佳表現 (0.660)，顯示其效益主要來自排程決策品質而非充電車數量；NJNP 與 Genetic+2-OPT 的邊際效益則最為有限，增加充電車僅提升約 3.7 個百分點。多數方法於 4 台後趨於平緩而未接近 1.0。以 HQARRF 為例，由 4 台增至 7 台，實際充電時間僅增加約 2%，移動距離與回站次數卻各增為 2.2 倍，傳遞至節點的總能量因而幾乎不變 (29,570→29,501 J)：新增的充電車多把時間耗在移動與回站往返，而非停靠充電。




圖 6. 不同行動充電車數量下的感測節點存活率

圖 7 進一步以重複實驗的存活率分布 (箱型圖) 驗證上述比較的穩定性，呈現各方法在隨機耗能情境下多次執行的存活率離散程度。HQARRF 的分布較集中、箱體較窄，表示其存活率改善並非依賴少數有利隨機場景，而是在重複執行下能保持一致表現。

為量化上述比較的統計可靠性，本文對圖 3 至圖 5 的 17 個參數點，將 HQARRF 與各點最強的非 HQARRF 方法成對比較；因重複次數不多，顯著性檢定採精確 (exact) Mann-Whitney U 檢定，並以 Cliff's delta 衡量效應量。各點最強者分別由 UCMC、Genetic+2-OPT 與 K-EDF 交替取得；在此 17 點子集上，HQARRF 平均領先 11.2 個百分點 (與前述 9.2 個百分點的差異僅來自參數點集合不同)，其中 11 點效應量達 large ($|d| \geq 0.474$)、5 點完全分離 ($d = +1.000$)、6 點達 $p < 0.05$ 。

差距與充電壓力高度相關：節點數量情境 (圖 4) 平均達 26.1 個百分點，五點全數完全分離且顯著；電池容量情境 (圖 5) 則隨容量由 100 J 增至 400 J，差距由 6.0 收斂至 0.4 個百分點。此一分布支持本文論點——充電壓力偏低時各方法皆能維持高存活率，區域介入沒有可發揮的空間，故本文並不主張 HQARRF 在所有設定下皆具顯著優勢，而是主張其在高充電壓力情境中同時具備統計顯著性與大效應量。




圖 7. 不同耗能率下重複實驗的存活率分布 (穩定性)

(三) 移動成本、充電效率與負載平衡

圖 8 與圖 9 比較總移動距離。路徑最佳化方法通常能取得較短距離，但較短移動不一定代表較高服務品質。




圖 8. 不同感測節點數量下各方法的總移動距離

圖 8 顯示，Genetic+2-OPT 因路徑最佳化而移動距離最短，HQARRF 距離居中至偏高，反映其需前往較遠高風險節點的設計特性；但 HQARRF 的移動距離隨節點數增加的成長幅度相對平緩，顯示區域介入對多充電車任務分配具有一定集中效果，避免了不必要的大幅移動。




圖 9. 不同場域大小下各方法的總移動距離

圖 9 顯示，隨場域增大，多數方法的總移動距離反而下降。其成因在於充電車須保留返回基地台的能量：場域放大後，較遠的候選目標無法通過可行性檢查，充電車的服務範圍相對集中，單趟行程因而縮短。Genetic+2-OPT 則因服務序列拉長而略為上升，惟其絕對移動距離仍為最低，需對照存活率共同判

斷。HQARRF 的移動距離接近低群組，表示其區域介入並未造成不合理的移動成本膨脹。

為避免「移動距離下降」被誤讀為服務退化，本文檢視同一組場域掃描下的服務品質指標（場域由 1000 m 放大至 3000 m，感測節點數與邊長等比例增加，故節點密度降為三分之一）。HQARRF 的總移動距離雖由 1.87×10^6 m 降至 8.44×10^5 m（約減少 55%），傳遞至節點的總能量卻由 2.24×10^4 J 增至 6.53×10^4 J，接近三倍，可見移動下降源自單位移動所換得服務量的提升，而非服務不足。存活率方面，場域擴張使各方法的服務範圍稀釋，整體水準均下降，但 HQARRF 由 0.800 降至 0.716，Genetic+2-OPT 則由 0.685 降至 0.506，兩者差距反而由 11.5 擴大至 21.0 個百分點。因此移動距離須與存活率、傳遞能量並列判讀，方能區分「有效率」與「服務不足」兩種截然不同的低移動成因。




圖 10. 不同感測節點數量下傳遞至感測節點的能量

圖 10 顯示，隨感測節點數量增加，HQARRF 的傳遞能量在各密度下均高於其他方法，節點越密集時差距越明顯，表示其排程能在服務容量有限時優先導向高風險區域。




圖 11. 不同行動充電車速度下傳遞至感測節點的能量

圖 11 顯示，即使充電車速度提高，HQARRF 的傳遞能量優勢仍持續，表示其排程邏輯在速度更快的充電車下同樣能將額外服務容量轉換為高風險區域的充電收益。




圖 12. 不同感測節點數量下的多充電車移動負載平衡

圖 12 以各充電車移動距離的變異係數 (CV) 衡量負載均衡度，數值越低代表任務分配越均衡。HQARRF 的 CV 在多數節點規模下相對偏低，顯示其區域介入與多充電車協調能有效分散充電任務，避免負載集中於少數充電車。相比之下，Genetic+2-OPT 的 CV 偏高，顯示路徑最佳化設計本身不具備多充電車協調能力；ARR-F 的 CV 居中，反映斥力項已提供一定的隱式負載分散效果。

圖 13(a) 顯示 HQARRF 的回充時間高於其他方法，因主動前往遠端高風險節點每趟耗能較多；圖 13(b) 則顯示其回充次數顯著少於 NJNP、AR 等局部貪婪方法。兩項指標合計呈現「少次但長時」的回充特徵，為主動服務遠端節點所付出的代價；ARR-F 的兩指標均居中，反映斥力與力場感知能有效減少短途無效任務。




圖 13(a). 不同感測節點數量下各方法的基地台回充時間




圖 13(b). 不同感測節點數量下各方法的基地台回充次數

六、討論

HQARRF 有效的主要原因在於分工明確：下層 ARR-F 以可解釋的吸引、斥力與力場項處理候選目標排序，上層 Q-learning 只在區域風險高且覆蓋不足時介入，因此避免把所有節點與充電車組合交給單一大型學習模型處理。

此設計也有適用限制。若節點分布極度稀疏、充電壓力很低，或高風險節點長期集中於單一小區域，區域介入相對於局部 ARR-F 的額外效益可能下降；若區域過大，風險估計會被平均化，若區域過小，則可能造成介入判斷波動。

在參數敏感度方面，較關鍵者包括區域數、風險門檻 θ_r 、覆蓋門檻 θ_c 、斥力係數 β 與力場係數 λ_f 。其中區域數已透過獨立掃描檢驗：將 Z 由 2 掃描至 16，存活率呈明顯的倒 U 形， $Z=6$ 附近最佳 (0.768)， $Z=2$ 與 $Z=16$ 則分別降至 0.564 與 0.668。其敏感度亦取決於充電壓力——節點密度較低的 2000 m 與 3000 m 大場域中，存活率全距僅 0.012 與 0.000，幾乎不受區域數影響；500 節點的高密度情境則放大至 0.310 且最佳區域數上移，佐證本文採用自適應區域數的作法。 θ_r 、 θ_c 與 λ_f 的系統性掃描則列為後續工作。

七、結論

本文提出 HQARRF，以 ARR-F 為下層候選叢集評分機制，輔以自適應區域風險估計與 Q-learning 上層介入。

模擬結果顯示，HQARRF 在不同耗能率、節點數量、電池容量、充電車數量、場域大小與充電車速度設定下皆能提升節點存活表現；於其中五組情境共 27 個參數點中，有 26 點取得最高存活率，相對五種基準方法平均值提升約 20.7 個百分點。相較於只重視局部急迫度或移動距離的排程方式，HQARRF 更適合被視為一種風險感知的多充電車資源分配框架。

本研究以靜態場域與單一基地台架構進行評估；動態拓撲、多基地台及異質充電設備等挑戰有待進一步驗證。未來研究方向包括具能量收集能力節點情境的延伸與大規模場域的計算效率分析；在自動參數調整方面，可以中繼學習 (meta-learning) 由情境特徵映射至 θ_r 、 θ_c 與區域數，或以存活節點剩餘能量的變異係數即時縮放斥力係數 β ，使方法移至新場域時不需重新網格搜尋。

致謝

本研究承蒙國家科學及技術委員會（計畫編號：NSTC 114-2221-E-005-043-MY3）經費補助，特此誌謝。

參考文獻

- [1] L. Xie, Y. Shi, Y. T. Hou, and H. D. Sherali, "Making Sensor Networks Immortal: An Energy-Renewal Approach With Wireless Power Transfer," *IEEE/ACM Transactions on Networking*, vol. 20, no. 6, pp. 1748–1761, 2012.
- [2] S. He, J. Chen, F. Jiang, D. K. Y. Yau, G. Xing, and Y. Sun, "Energy Provisioning in Wireless Rechargeable Sensor Networks," *IEEE Transactions on Mobile Computing*, vol. 12, no. 10, pp. 1931–1942, 2013.
- [3] X. Lu, P. Wang, D. Niyato, D. I. Kim, and Z. Han, "Wireless Charging Technologies: Fundamentals, Standards, and Network Applications," *IEEE Communications Surveys & Tutorials*, vol. 18, no. 2, pp. 1413–1452, 2016.
- [4] C. Wang, J. Li, F. Ye, and Y. Yang, "Recharging Schedules for Wireless Sensor Networks with Vehicle Movement Costs and Capacity Constraints," *IEEE SECON*, pp. 468–476, 2014.
- [5] Y. Ma, W. Liang, and W. Xu, "Charging Utility Maximization in Wireless Rechargeable Sensor Networks by Charging Multiple Sensors Simultaneously," *IEEE/ACM Transactions on Networking*, vol. 26, no. 4, pp. 1591–1604, 2018.
- [6] G. Han, H. Guan, J. Wu, S. Chan, L. Shu, and W. Zhang, "An Uneven Cluster-Based Mobile Charging Algorithm for Wireless Rechargeable Sensor Networks," *IEEE Systems Journal*, vol. 13, no. 4, pp. 3747–3758, 2019.
- [7] G. Han, H. Wang, H. Guan, and M. Guizani, "A Mobile Charging Algorithm Based on Multicharger Cooperation in Internet of Things," *IEEE Internet of Things Journal*, vol. 8, no. 2, pp. 684–694, 2021.
- [8] Z. Wei, M. Li, Q. Zhao, Z. Lyu, S. Zhu, and Z. Wei, "Multi-MC Charging Schedule Algorithm With Time Windows in Wireless Rechargeable Sensor Networks," *IEEE Access*, vol. 7, pp. 156217–156227, 2019.
- [9] C. J. C. H. Watkins and P. Dayan, "Q-Learning," *Machine Learning*, vol. 8, no. 3–4, pp. 279–292, 1992.
- [10] C. Jiang et al., "Attention-Shared Multi-Agent Actor-Critic-Based Deep Reinforcement Learning Approach for Mobile Charging Dynamic Scheduling in Wireless Rechargeable Sensor Networks," *Entropy*, vol. 24, no. 7, article 965, 2022.
- [11] H. Wang, J. Li, and W. Xiao, "Reinforcement Learning-Based Charging Cluster Determination Algorithm for Optimal Charger Placement in Wireless Rechargeable Sensor Networks," *Ad Hoc Networks*, vol. 164, article 103605, 2024.